

Задача №2. Тестирование последовательностей псевдослучайных чисел.

Датчики псевдослучайных чисел разрабатываются так, чтобы генерируемые ими последовательности можно было считать реализациями независимых случайных величин, равномерно распределённых на единичном отрезке. Ваше задание — реализовать такой датчик и проверить генерируемую последовательность на равномерность и независимость.

Выполните следующие шаги:

1. Рассчитайте 100 псевдослучайных чисел методом, соответствующим вашему варианту. Описание методов дано на второй и третьей страницах.
 2. Приведите первые 10 чисел этой последовательности.
 3. Постройте гистограмму с 10 столбцами для полученной последовательности.
 4. Проверьте гипотезу о том, что последовательность имеет распределение $R(0, 1)$ критерием хи-квадрат, разбив интервал $[0; 1)$ на десять равных интервалов.
 5. Повторите шаги 3 и 4 для последовательности длиной в 10000 чисел.
 6. Изучите тест перестановок (он описан на третьей странице) и проверьте этим тестом первые 9999 чисел вашей последовательности, разбив их на тройки.
- Используйте уровень значимости 5%.

Методы генерации псевдослучайных чисел и проверяющие по вариантам:

Степенной остаточный №2.

Назначаем начальное число $z_1 < 10000$. Последующие числа получаем из соотношения $z_i = ((z_{i-1} + 17)^{2.2} \text{ div } 100) \bmod 10000$, div — целая часть от деления, mod — остаток от деления.

Полученная последовательность укладывается в пределы от 0 до 1 так: $x_i = \frac{z_i}{10000}$.

1. Требуется рассчитать 100 псевдослучайных чисел данным методом, $z_1 = 7724$. Напишем функцию, создающую требуемый массив чисел на языке Matlab:

```
makestat.m x +
1 function stat = makestat(stat, size, first)
2     stat(1) = first;
3 for i = 2:size
4     prevval = stat(length(stat));
5     newval = mod(fix(power(prevval + 17, 2.2)/100), 10000);
6     stat(length(stat)+1) = newval;
7 end
```

Теперь создадим переменную для массива и вызовем функцию для 100 элементов и первого числа 7724

```
>> stat = [];
>> stat = makestat(stat, 100, 7724)
```

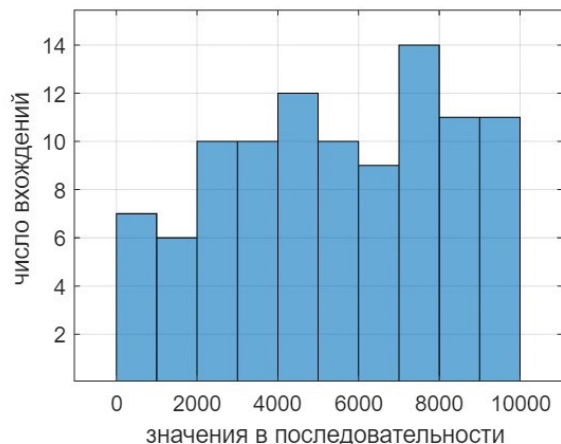
2. Выведем первые 10 чисел последовательности:

```
>> stat(1:10)
```

ans =

7724 2142 6449 7678 5348 3442 507 9605 6739 2669

3. Построим гистограмму из 10 столбцов для полученной последовательности:



```
>> histogram(stat, 10)
```

4. Проверим гипотезу о том, что последовательность имеет распределение $R(0,1)$ критерием хи-квадрат.

Для этого разобьём интервал $[0, 1)$ на десять равных интервалов $[x_i; x_{i+1})$, рассчитаем для равномерного распределения частоты попадания чисел в каждый интервал - η_i , затем уложим последовательность в нужный интервал с помощью описанной в степенном остаточном методе формулы и вычислим частоты попадания чисел в интервалы для чисел нормализованной последовательности - π_i .

Составим гипотезы:

$H_0: \forall i \pi_i = \eta_i$ - основная гипотеза - частоты соответствуют частотам $R(0,1)$

$H_A: \exists j: \pi_j \neq \eta_j$ - альтернативная гипотеза, любое отклонение от H_0

Проверять гипотезу будем с помощью статистики:

$\chi^2 = \sum_{j=1}^n (\pi_j - \eta_j)^2 / \eta_j \sim H_0 \sim \chi^2(k-1)$, - распределение хи-квадрат с $k-1$ степенями свободы, где π_j - наблюдаемые частоты, η_j - ожидаемые частоты, k - число наблюдений = 10 в нашем случае (равно числу интервалов)

Мы должны отвергнуть гипотезу H_0 , если рассчитанная статистика будет больше значения квантили $\chi^2(k-1)$ уровня α , где α - уровень значимости, в нашем случае равен 0.05

Найдём в таблице критическую квантили $\chi^2(k-1)$ α : $\chi^2(9) 0.05 = 16.919$

Теперь рассчитаем статистику. Для этого построим интервалы $[x_i; x_{i+1})$:
 $[0;0.1), [0.1;0.2), [0.2;0.3), [0.3;0.4), [0.4;0.5), [0.5;0.6), [0.6;0.7), [0.7;0.8), [0.8;0.9), [0.9;1)$,
 вычислим ожидаемые частоты как (длина последовательности / число интервалов) =
 $100/10 = 10$

Для нахождения наблюдаемых частот уложим последовательность в интервал $[0,1)$ по формуле $ns_i = s_i/10000$:

```
>> normstat = normalizestat(stat)
```

```
normstat =
```

```
Columns 1 through 20
```

```
0.7724 0.2142 0.6449 0.7678 0.5348 0.3442 0.0507 0.9605
```

```
Columns 21 through 40
```

```
0.0577 0.2656 0.6256 0.1755 0.0158 0.0860 0.9826 0.3691
```

```
normalizestat.m x countpermutations.m x countdiff.m x
1 function normstat = normalizestat(stat)
2 normstat = zeros(1, length(stat));
3 for i = 1:length(stat)
4 normstat(i) = stat(i)/10000;
5 end
```

Для каждого из 10 равных интервалов найдём, сколько чисел в него попало

```
>> observedfreq = countfrequencies(normstat)
```

```
observedfreq =
```

```
7 6 10 10 12 10 9 14 11 11
```

```
countfrequencies.m x normalizestat.m x countpermutations.m x countdiff.m x makestat.m x
1 function freq = countfrequencies(stat)
2 freq = [0,0,0,0,0,0,0,0,0,0];
3 for i = 1:length(stat)
4 freq(freq(stat(i)*10)+1) = freq(freq(stat(i)*10)+1) + 1;
5 end
6 end
```

Теперь для каждого интервала найдём $(n_j - \eta_j)^2/\eta_j$ и просуммируем:

x_i	x_{i+1}	η_i	n_i
0	0.1	10	7
0.1	0.2	10	6
0.2	0.3	10	10
0.3	0.4	10	10
0.4	0.5	10	12
0.5	0.6	10	10
0.6	0.7	10	9
0.7	0.8	10	14
0.8	0.9	10	11
0.9	1	10	11

```
countpermutations.m x makestat.m x countdiff.m x
1 function res = countdiff(expected, observed)
2 res = 0;
3 for i = 1:length(expected)
4 res = res + power((observed(i) - expected(i)), 2)/expected(i);
5 end
```

```
normalfreq =
```

```
10 10 10 10 10 10 10 10 10 10
```

```
>> res = countdiff(normalfreq, observedfreq)
```

```
res =
```

```
4.8000
```


$\chi^2 = 4.8$

Сравним с критической квантилью $\chi^2(9) 0.05 = 16.919$

$4.8 < 16.919$ $\chi^2 < \chi^2(5) 0.05$

На уровне значимости 5% мы не отвергаем гипотезу H_0 , и считаем что полученная последовательность из 100 чисел имеет распределение $R(0,1)$

5. Сделаем то же самое для последовательности длиной 10000 элементов:
Сгенерируем последовательность и построим гистограмму:



```
>> stat10000 = [];  
>> stat10000 = makestat(stat10000, 10000, 7724);  
>> histogram(stat10000, 10)
```

Проверим гипотезу о том, что последовательность имеет распределение $R(0,1)$ критерием хи-квадрат.

Для этого разобьём интервал $[0, 1)$ на десять равных интервалов $[x_i; x_{i+1})$, рассчитаем для $R(0,1)$ частоты попадания чисел в каждый интервал - η_i , затем уложим последовательность в нужный интервал с помощью описанной в степенном остаточном методе формулы и вычислим частоты попадания чисел в интервалы для чисел нормализованной последовательности - π_i .

Составим гипотезы:

$H_0: \forall i \pi_i = \eta_i$ - основная гипотеза - частоты соответствуют частотам $R(0,1)$

$H_A: \exists j: \pi_j \neq \eta_j$ - альтернативная гипотеза, любое отклонение от H_0

Проверять гипотезу будем с помощью статистики:

$\chi^2 = \sum_{j=1}^{10} (\pi_j - \eta_j)^2 / \eta_j \sim H_0 \sim \chi^2(k-1)$, - распределение хи-квадрат с $k-1$ степенями свободы, где π_j - наблюдаемые частоты, η_j - ожидаемые частоты, k - число наблюдений = 10 в нашем случае (равно числу интервалов)

Мы должны отвергнуть гипотезу H_0 , если рассчитанная статистика будет больше значения квантили $\chi^2(k-1)$ уровня α , где α - уровень значимости, в нашем случае равен 0.05

Найдём в таблице критическую квантиль $\chi^2(k-1)$ $\alpha: \chi^2(9) 0.05 = 16.919$

Теперь рассчитаем статистику. Для этого построим интервалы $[x_i; x_{i+1})$, вычислим ожидаемые частоты как длина последовательности / число интервалов = $10000/10 = 1000$

Для нахождения наблюдаемых частот уложим последовательность в интервал [0,1):

```
>> normstat10000 = normalizestat(stat10000)

normstat10000 =

Columns 1 through 20

    0.7724    0.2142    0.6449    0.7678    0.5348    0.3442
```

Для каждого из 10 равных интервалов найдём, сколько чисел в него попало

```
>> observedfreq10000 = countfrequencies(normstat10000)

observedfreq10000 =

    205    600    1000    1000    1398    1198    801    1598    1199    1001

>> normalfreq10000 = [1000,1000,1000,1000,1000,1000,1000,1000,1000,1000]

normalfreq10000 =

    1000    1000    1000    1000    1000    1000    1000    1000    1000    1000
```

Теперь для каждого интервала найдём $(n_j - \eta_j)^2 / \eta_j$ и просуммируем:

ξ_i	ξ_{i+1}	η_i	n_i
0	0.1	1000	205
0.1	0.2	1000	600
0.2	0.3	1000	1000
0.3	0.4	1000	1000
0.4	0.5	1000	1398
0.5	0.6	1000	1198
0.6	0.7	1000	801
0.7	0.8	1000	1598
0.8	0.9	1000	1199
0.9	1	1000	1001

```
>> res = countdiff(normalfreq10000, observedfreq10000)

res =

    1.4264e+03
```

$\chi^2 = 1426.4$
Сравним с критической квантилью $\chi^2(9)_{0.05} = 16.919$
 $1426.4 > 16.919 \quad \chi^2 > \chi^2(5)_{0.05}$

На уровне значимости 5% мы отвергаем гипотезу H_0 , и считаем что полученная последовательность из 10000 чисел не имеет распределение $R(0,1)$

6. Тест перестановок. Посчитаем количество перестановок каждого вида в последовательности из 9999 первых элементов полученной последовательности и проверим с помощью критерия хи-квадрат гипотезу о том, что числа независимы - об этом свидетельствует равновероятность появления каждого типа перестановок. Пусть x_1, \dots, x_k - перестановки из 3 чисел, p_1, \dots, p_k - вероятности их появления.

Составим гипотезы:

$H_0: p_1=p_2=p_3=p_4=p_5=p_6=1/6$ - основная гипотеза - перестановки равновероятны

$H_A: \exists j: p_j \neq 1/6$ - альтернативная гипотеза, любое отклонение от H_0

Проверять гипотезу будем с помощью статистики:

$\chi^2 = \sum_{j=1}^k (O_j - E_j)^2 / E_j \sim H_0 \sim \chi^2(k-1)$, - распределение хи-квадрат с $k-1$ степенями свободы, где O_j - наблюдаемые частоты, E_j - ожидаемые частоты, k - число наблюдений = 6 в нашем случае

Мы должны отвергнуть гипотезу H_0 , если рассчитанная статистика будет больше значения квантили $\chi^2(k-1)$ уровня α , где α - уровень значимости, в нашем случае равен 0.05

Найдём в таблице критическую квантили $\chi^2(k-1)$ $\alpha: \chi^2(5) 0.05 = 11.07$

Теперь вычислим статистику.

Напишем функцию, которая будет разбивать последовательность на тройки и подсчитывать частоту каждой перестановки:

```
countpermutations.m * makestat.m +
1 function permutations = countpermutations(stat)
2     permutations = [0,0,0,0,0,0];
3     for i = 1:length(stat)/3
4         first = stat(3*i-2);
5         second = stat(3*i-1);
6         third = stat(3*i);
7
8         if first>second
9             if second> third
10                permutations(6) = permutations(6)+1;
11            elseif first>third
12                permutations(5) = permutations(5)+1;
13            else
14                permutations(3) = permutations(3)+1;
15            end
16        else
17            if second> third
18                if first>third
19                    permutations(4) = permutations(4)+1;
20                else
21                    permutations(2) = permutations(2)+1;
22                end
23            else
24                permutations(1) = permutations(1)+1;
25            end
26        end
27    end
```

```
%permutations[1] - 123
%permutations[2] - 132
%permutations[3] - 213
%permutations[4] - 231
%permutations[5] - 312
%permutations[6] - 321
```


Вызвав эту функцию от последовательности получаем значения O1, ... O6

```
>> statpermutations = countpermutations(stat10000(1:9999))
```

```
statpermutations =
```

```
601    667    467    465    666    467
```

Соответствующие E_j для всех $j = 9999/18 = 555.5$

Вычислим статистику $\chi^2 = \sum_{j=1}^6 (O_j - E_j)^2 / E_j$:

```
>> normalpermutations = [555.5, 555.5, 555.5, 555.5, 555.5, 555.5];
```

```
>> countdiff(normalpermutations, statpermutations)
```

```
ans =
```

```
91.0306
```

$\chi^2 = 91.0306$ - значение статистики

Сравним χ^2 и критическую квантиль $\chi^2(5) 0.05 = 11.07$

$91.0306 > 11.07$ $\chi^2 > \chi^2(5) 0.05$

На уровне значимости 5% мы отвергаем гипотезу H_0 о том, что перестановки распределены равномерно

Согласно тесту перестановок получаем, что на уровне значимости 5% числа в последовательности зависимы.